CESDE

Taller 4. Visualizar para comprender

De los datos a una historia clara y verificable

Guía del estudiante

Caso: Observatorio académico del centro de formación
Datos sintéticos • CSV y SQLite • Python, pandas, Matplotlib, Seaborn y Plotly

Docente: Gustavo Montoya
Duración sugerida: 4 horas
Modalidad: demostración guiada + retos prácticos

Antes de empezar

Este taller comienza desde cero en visualización y no depende de actividades anteriores. Trabajará con archivos CSV y, de manera opcional, con una base SQLite local, usando conocimientos ya practicados: estructura de proyecto, entorno virtual, pandas, filtros, agrupaciones, uniones y consultas.

IDEA CENTRAL: un gráfico no es decoración; es una respuesta visual a una pregunta.

Resultados de aprendizaje

- Reconocer variables cualitativas y cuantitativas.
- Elegir el gráfico según la pregunta: comparar, evolucionar, distribuir, relacionar o componer.
- Construir visualizaciones con pandas, Matplotlib y Seaborn.
- Crear una visualización interactiva sencilla con Plotly y guardarla como HTML.
- Detectar errores de escala, color, etiquetas y conclusiones sin evidencia.
- Explicar hallazgos con lenguaje claro y responsable.

Ruta de trabajo

1. Formular una pregunta.

2. Identificar variables y unidades.

3. Preparar datos con pandas o SQLite.

4. Elegir la familia de gráfico.

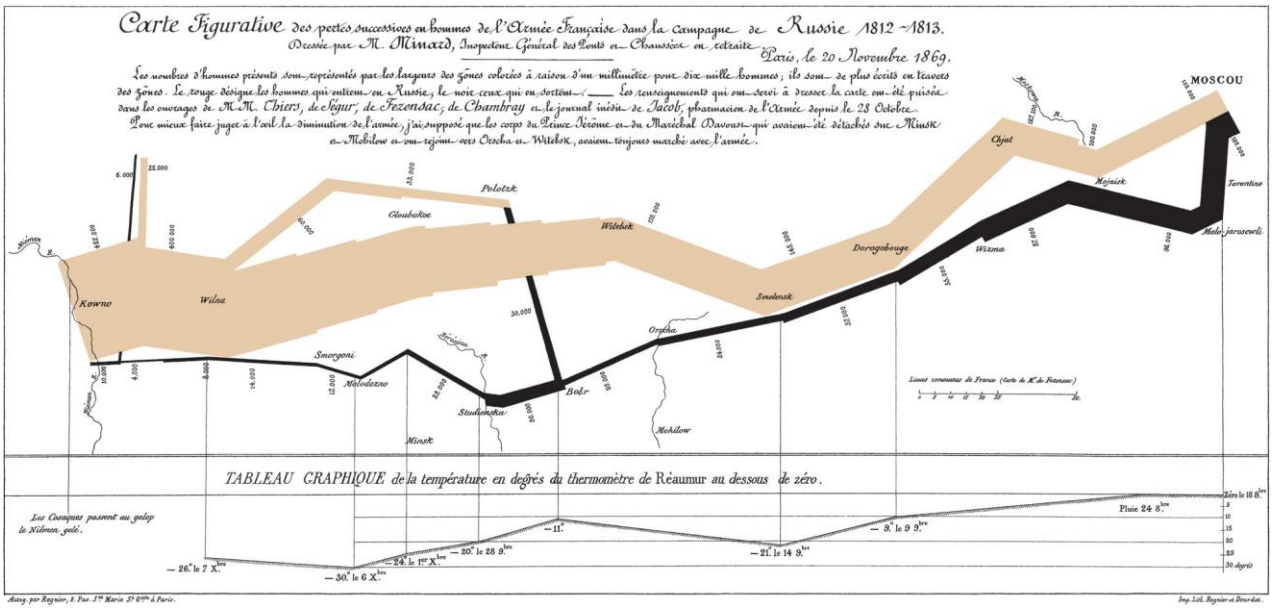
5. Construir y revisar.

6. Interpretar sin exagerar.

7. Comunicar una recomendación.

1. Activación: leer antes de programar

Observe el mapa de Charles Joseph Minard sobre la campaña de Napoleón en Rusia. Antes de leer la explicación, dedique dos minutos a responder: ¿qué cambia?, ¿qué representa el ancho?, ¿qué diferencia los colores?, ¿qué agrega la gráfica inferior?



Mapa original de Minard, publicado en 1869.

Por qué esta visualización hizo historia

En 1812, Napoleón Bonaparte inició una campaña militar contra Rusia con un ejército de cientos de miles de hombres. El avance llegó hasta Moscú, pero la retirada estuvo marcada por combates, enfermedades, hambre, agotamiento y temperaturas extremas. Décadas después, en 1869, el ingeniero francés Charles Joseph Minard convirtió esa tragedia histórica en una explicación visual que todavía se estudia en cursos de análisis de datos.

La banda clara representa el avance hacia Moscú y la banda oscura muestra el regreso. Su ancho cambia según la cantidad aproximada de soldados que permanecían en el ejército: cuando la banda se hace más delgada, entendemos inmediatamente que el número de hombres disminuyó. El recorrido se ubica sobre un mapa, por lo que también podemos reconocer ciudades, desvíos y puntos de encuentro. En la parte inferior, Minard incorporó las fechas y las temperaturas registradas durante la retirada.

Su aporte fue reunir en una sola imagen varias variables que normalmente aparecerían separadas: ubicación, dirección del viaje, cantidad de soldados, tiempo y temperatura. Así, el lector no recibe una lista de cifras aisladas; puede seguir el recorrido, comparar momentos y observar la magnitud de las pérdidas. Esta capacidad de integrar información compleja en una historia comprensible convirtió el mapa en una referencia mundial de la visualización de datos.

La gráfica también enseña una regla que sigue vigente: una buena visualización debe responder una pregunta y permitir que la evidencia sea visible. Sin embargo, debe interpretarse con cuidado. La cercanía entre la caída de la temperatura y la reducción del ejército aporta contexto, pero el dibujo por sí solo no demuestra que el frío haya sido la única causa. Para explicar completamente lo ocurrido también se necesitan fuentes históricas sobre combates, enfermedades, alimentación y decisiones militares.

Posición	Ruta geográfica del ejército.
Ancho	Cantidad de soldados: disminuye de forma dramática.
Color	Avance y retirada.
Línea inferior	Temperatura durante el regreso.
Lección	Una buena visualización integra variables para contar una historia verificable.

Actividad en parejas: escriban tres hallazgos visibles y una pregunta que el mapa no responda. Después separen hechos observables de interpretaciones.

2. Tipos de variables e intención

Cualitativa nominal	Categorías sin orden: ciudad, modalidad, estado. Use barras o composición.
Cualitativa ordinal	Categorías con orden: nivel socioeconómico, satisfacción. Respete el orden.
Cuantitativa discreta	Conteos enteros: matrículas, cursos. Barras o distribución.
Cuantitativa continua	Mediciones: nota, progreso, precio. Histograma, caja o dispersión.
Temporal	Fechas y periodos ordenados. Líneas, áreas o escalonado.

Para elegir el gráfico no empiece por Matplotlib, Seaborn o Plotly. Primero escriba la pregunta y reconozca qué desea hacer: comparar, observar un cambio, estudiar una distribución, relacionar variables o mostrar partes de un total.

¿Qué quiere descubrir con los datos?

Busque el verbo de la pregunta y elija la familia de gráfico

1. PREGUNTA	2. INTENCIÓN	3. GRÁFICO
¿Qué producto se vende más?	Comparar	Barras
¿Cómo cambian las ventas cada mes?	Ver cambios	Líneas o áreas
¿En qué valores se concentran las notas?	Ver distribución	Histograma o caja
¿Las horas de estudio se relacionan con la nota?	Relacionar	Dispersión
¿Cómo se reparte el presupuesto?	Ver partes del total	Apiladas, dona o treemap

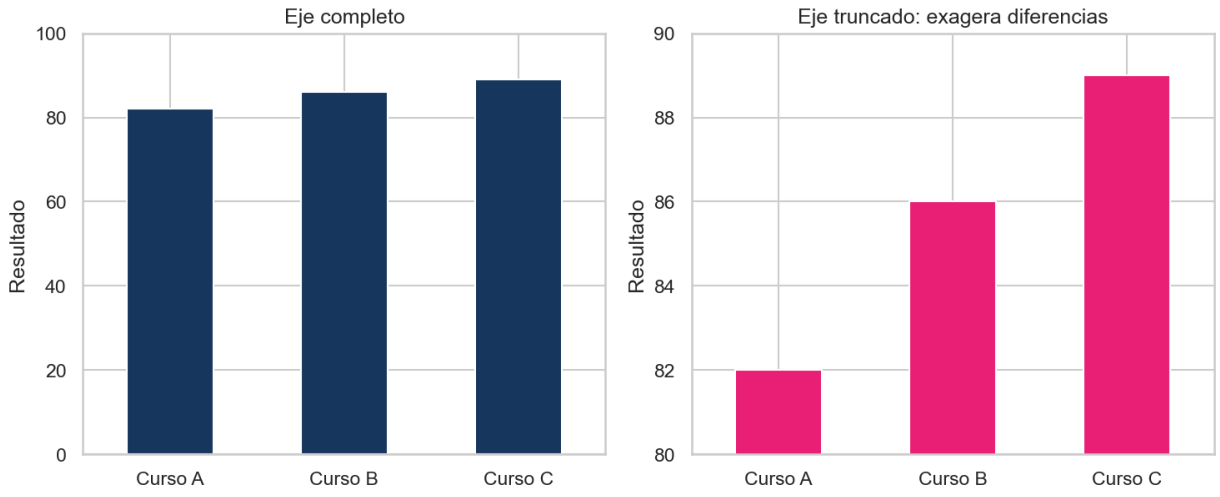
Si solo necesita mostrar un número, use una tarjeta o KPI; no necesita un gráfico.

Guía de decisión: de una pregunta concreta al tipo de gráfico.

La pregunta manda

- Comparar: ¿qué curso tiene más matrículas?
- Evolucionar: ¿cómo cambian las matrículas cada mes?
- Distribuir: ¿cómo se concentran las notas?
- Relacionar: ¿progreso y nota se mueven juntos?
- Componer: ¿qué proporción está activa, finalizada o retirada?

Una gráfica puede engañar



Los mismos valores parecen muy distintos cuando el eje se recorta.

Reto de observación: ¿cuál vista permite comparar honestamente? Explique por qué el eje truncado exagera una diferencia de pocos puntos.

3. Preparar el proyecto

```
visualizaciones_cesde/
|-- .venv/
|-- data/
|   |-- raw/
|   |   |-- estudiantes.csv
|   |   |-- cursos.csv
|   |   `-- inscripciones.csv
|   `-- processed/
|       `-- dataset_analitico.csv
|-- database/
|   `-- centro_formacion.db
|-- graficos/
|-- Taller_Visualizaciones.ipynb
`-- requirements.txt
```

Crear el entorno e instalar

```
py -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install pandas numpy matplotlib seaborn plotly squarify notebook
jupyter notebook
```

En macOS o Linux use python3 -m venv .venv y source .venv/bin/activate.

Importaciones comunes

```
from pathlib import Path
import sqlite3
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px

BASE = Path(__file__).resolve().parent
GRAFICOS = BASE / 'graficos'
GRAFICOS.mkdir(parents=True, exist_ok=True)
sns.set_theme(style='whitegrid', palette='colorblind')
```

Elija una sola ruta de carga. Las dos opciones crean un DataFrame llamado `df`; por eso todo el código posterior funciona igual con CSV o SQLite.

Ruta A. Trabajar con CSV

```
# Opción directa: dataset analítico ya preparado
ruta_csv = BASE / 'data' / 'processed' / 'dataset_analitico.csv'
df = pd.read_csv(ruta_csv, parse_dates=['fecha'])
print(df.shape)
print(df.head())
```

Si desea practicar uniones, puede reconstruir el dataset a partir de los tres CSV de la carpeta `data/raw`.

```
estudiantes = pd.read_csv(BASE / 'data' / 'raw' / 'estudiantes.csv')
cursos = pd.read_csv(BASE / 'data' / 'raw' / 'cursos.csv')
inscripciones = pd.read_csv(BASE / 'data' / 'raw' / 'inscripciones.csv',
                            parse_dates=['fecha'])

df = (inscripciones
      .merge(estudiantes, on='estudiante_id', how='left')
      .merge(cursos, on='curso_id', how='left'))

df['mes'] = df['fecha'].dt.to_period('M').astype(str)
df['aprobado'] = (df['nota'] >= 3.0) & (df['progreso'] >= 70)
```

Ruta B. Trabajar con SQLite

SQLite viene incluido con Python mediante `sqlite3`; no requiere servidor ni una instalación separada. La base entregada contiene las tablas `estudiantes`, `cursos`, `inscripciones` y `dataset_analitico`.

```
ruta_db = BASE / 'database' / 'centro_formacion.db'

with sqlite3.connect(ruta_db) as conexion:
    tablas = pd.read_sql_query(
        "SELECT name FROM sqlite_master WHERE type='table' ORDER BY name",
        conexion
    )
    print(tablas)
    df_sql = pd.read_sql_query('SELECT * FROM dataset_analitico', conexion)

df = df_sql.copy()
df['fecha'] = pd.to_datetime(df['fecha'])
print(df.shape)
print(df.head())
```

El bloque `with` cierra automáticamente la conexión. Para practicar SQL puede reemplazar la consulta por `SELECT curso, nota, progreso FROM dataset_analitico WHERE estado = 'Activa'`.

Preparación mínima antes de graficar

```
print(df.shape)
print(df.dtypes)
print(df.isna().sum())
print(df.duplicated().sum())

# Ejemplo de resumen reutilizable
resumen = (df.groupby('curso', as_index=False)
             .agg(inscripciones=('inscripcion_id', 'count'),
                  nota_promedio=('nota', 'mean'))
             .sort_values('inscripciones', ascending=False))
```

4. Librerías de visualización

Las librerías no compiten: se complementan. Para aprender, conviene dominar la lógica de Matplotlib, usar Seaborn para estadística y Plotly cuando la interactividad aporta valor.

Herramienta	Fortaleza	Dificultad	Salida	Uso recomendado
pandas.plot	Rápido desde un DataFrame	Baja	Estática	Exploración inicial
Matplotlib	Control total	Media	Estática	Comprender cada parte del gráfico
Seaborn	Gráficos estadísticos	Baja-media	Estática	Distribuciones y relaciones
Plotly	Zoom, filtros y tooltip	Media	HTML interactivo	Reporte compartible

Herramienta	Fortaleza	Dificultad	Salida	Uso recomendado
Altair	Gramática declarativa	Media	Interactiva	Exploración futura; no es requisito

Ejemplo equivalente en tres niveles

```
# 1. pandas: rápido
df['curso'].value_counts().head(5).plot.bar()

# 2. Matplotlib: control explícito
fig, ax = plt.subplots(figsize=(8, 4))
ax.bar(resumen['curso'].head(5), resumen['inscripciones'].head(5))

# 3. Seaborn: datos en formato largo
sns.barplot(data=resumen.head(5), x='curso', y='inscripciones')
```

Interactividad opcional con Plotly

```
import plotly.express as px

fig = px.scatter(df, x='progreso', y='nota', color='estado',
                 hover_data=['curso', 'nombre'],
                 title='Progreso y nota')
fig.show()
fig.write_html('graficos/reporte_interactivo.html')
```

El archivo HTML se abre en cualquier navegador. No necesita iniciar un servidor ni tener conexión a internet.

5. Atlas práctico: 20 visualizaciones

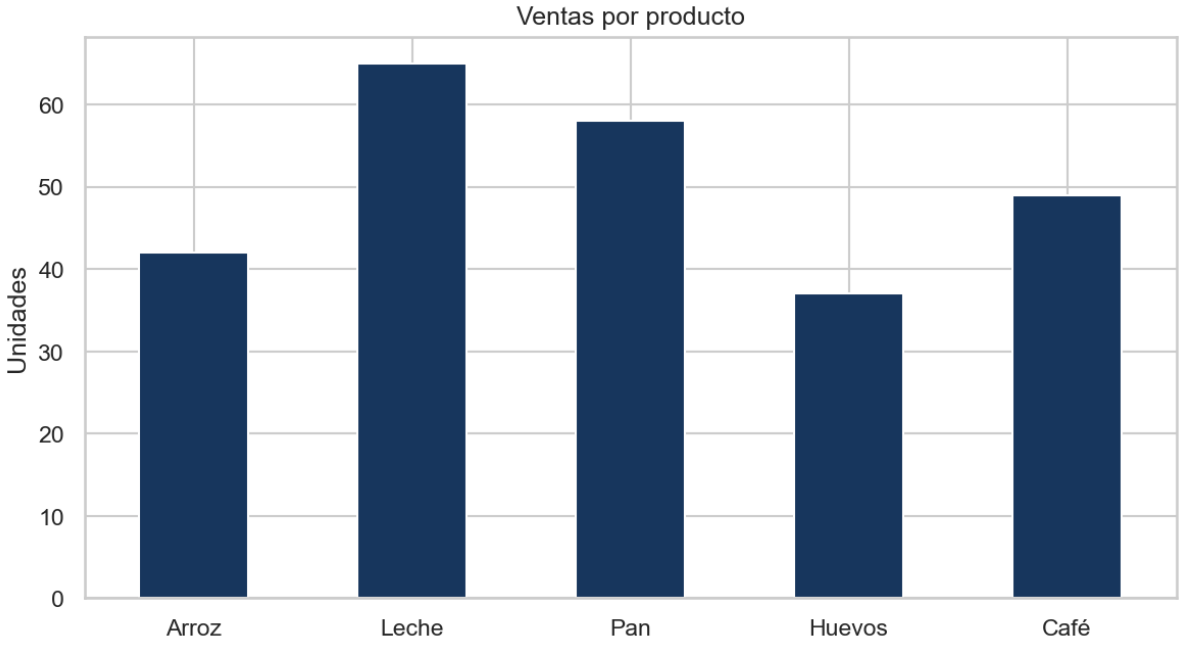
Cada ficha responde cuatro preguntas: para qué sirve, qué datos necesita, cómo se programa y cómo se interpreta. Antes de ejecutar el código, escriba una predicción.

01. Barras verticales

HISTORIA	Una tienda de barrio quiere organizar su próximo pedido. Antes de comprar mercancía necesita comparar cuántas unidades vendió de cada producto. Pregunta: ¿Qué producto tuvo más ventas?
Definición sencilla	Visualización para comparar magnitudes entre categorías.
Objetivo	Comparar magnitudes entre categorías.
Datos adecuados	Una categoría y una medida numérica o frecuencia.
Cuándo usarlo	Pocas categorías, etiquetas cortas y comparación directa.
Cuándo evitarlo	Muchas categorías o etiquetas largas.
Ventaja	La longitud se compara con facilidad.
Limitación	Pierde claridad al superar 10–12 barras.
Ejemplo contextual	Unidades vendidas por producto.
Cómo interpretarlo	La barra más alta representa la mayor cantidad; compare también la diferencia con el segundo lugar.
Errores frecuentes	Orden aleatorio, eje truncado y etiquetas inclinadas sin necesidad.
Consejo de diseño	Ordene de mayor a menor y use un color de destaque.

Código explicado

```
ventas = pd.Series({'Arroz': 42, 'Leche': 65, 'Pan': 58, 'Huevos': 37, 'Café': 49})
ventas.plot.bar(color='#17365D')
plt.title('Ventas por producto')
plt.ylabel('Unidades'); plt.show()
```



Ejemplo 1. Datos sintéticos de la historia.

RETO BREVE

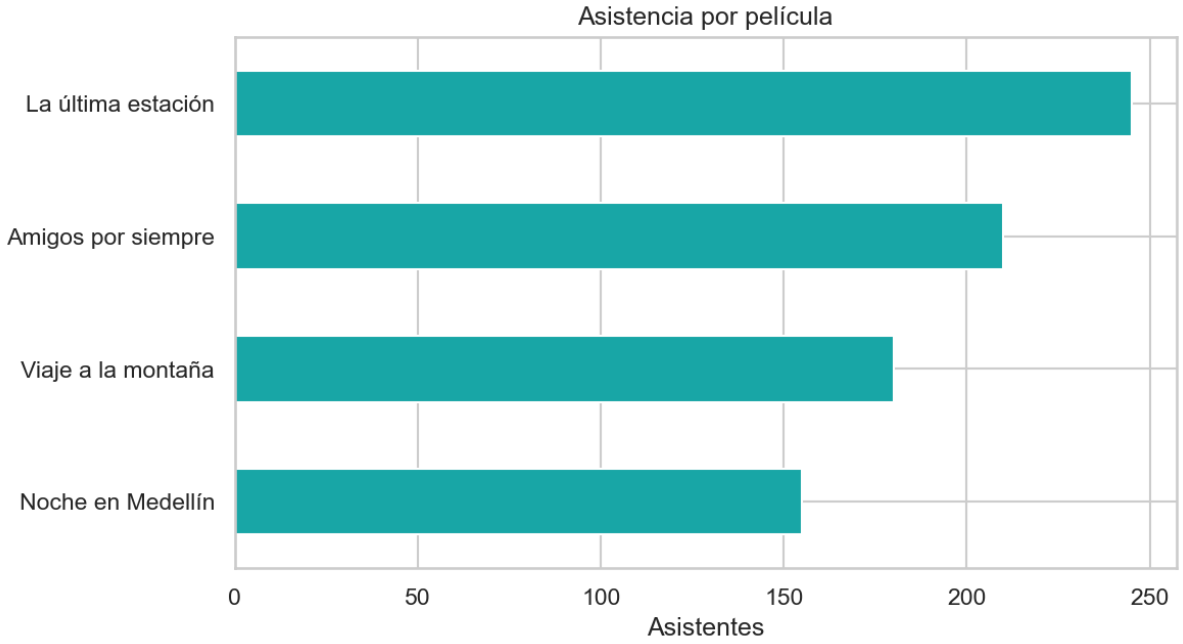
Cambie dos cantidades y compruebe si cambia el producto ganador.

02. Barras horizontales

HISTORIA	Un cine debe decidir qué películas conservar una semana más. Los nombres son largos y desea ordenar la asistencia de mayor a menor. Pregunta: ¿Qué película tuvo más asistentes?
Definición sencilla	Visualización para comparar y ordenar categorías con nombres largos.
Objetivo	Comparar y ordenar categorías con nombres largos.
Datos adecuados	Categoría + valor.
Cuándo usarlo	Rankings y listas ordenadas.
Cuándo evitarlo	Series de tiempo.
Ventaja	Las etiquetas se leen completas.
Limitación	No muestra bien cambios temporales.
Ejemplo contextual	Asistentes por película.
Cómo interpretarlo	La barra que llega más lejos a la derecha indica la mayor tasa.
Errores frecuentes	No convertir proporciones a porcentaje o no indicar la unidad.
Consejo de diseño	Ordene ascendente para que el mayor quede arriba.

Código explicado

```
cine = pd.Series({'Viaje a la montaña': 180, 'La última estación': 245, 'Amigos por siempre': 210, 'Noche en Medellín': 155})
cine.sort_values().plot.barh(color='#18A6A6')
plt.xlabel('Asistentes'); plt.show()
```



Ejemplo 2. Datos sintéticos de la historia.

RETO BREVE

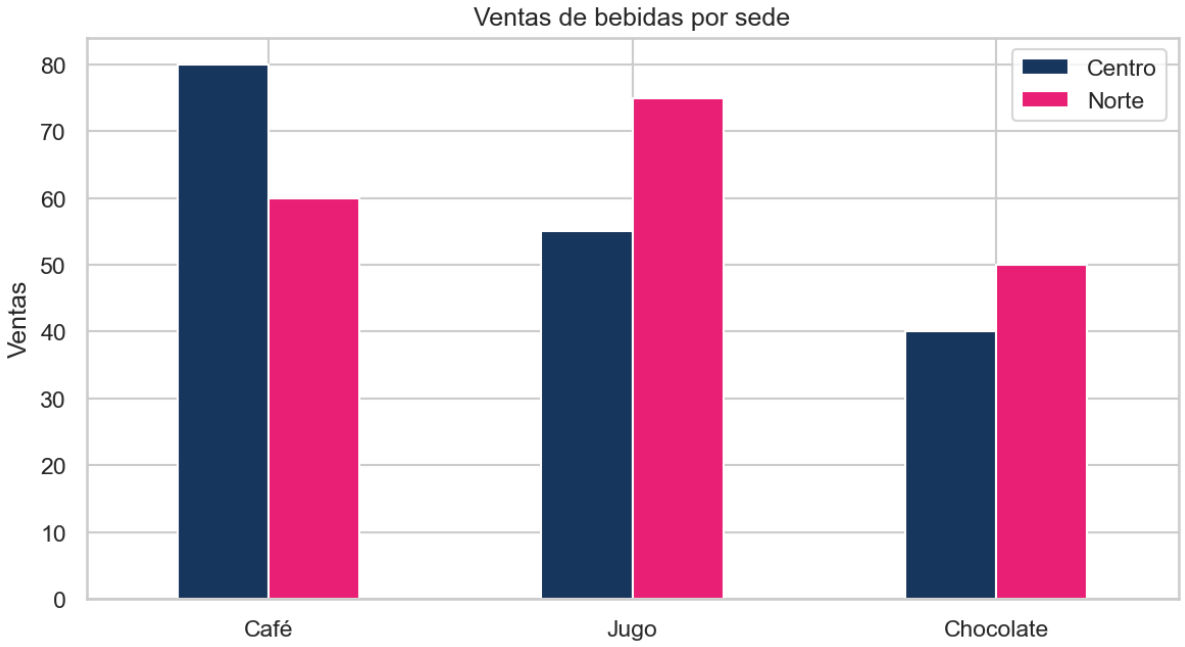
Agregue una quinta película y actualice el ranking.

03. Barras agrupadas

HISTORIA	Una cafetería vende bebidas en dos sedes. La administradora quiere comparar café, jugo y chocolate sin mezclar los resultados de cada local. Pregunta: ¿Qué bebida funciona mejor en cada sede?
Definición sencilla	Visualización para comparar subgrupos dentro de cada categoría.
Objetivo	Comparar subgrupos dentro de cada categoría.
Datos adecuados	Dos variables categóricas y una medida.
Cuándo usarlo	Cuando hay 2–4 subgrupos.
Cuándo evitarlo	Demasiadas combinaciones.
Ventaja	Permite comparación lado a lado.
Limitación	Se vuelve densa rápidamente.
Ejemplo contextual	Ventas de bebidas por sede.
Cómo interpretarlo	Compare barras del mismo grupo antes de comparar grupos distintos.
Errores frecuentes	Usar demasiados colores y no incluir leyenda.
Consejo de diseño	Mantenga el mismo orden de series en todos los grupos.

Código explicado

```
tabla = pd.DataFrame({'Centro':[80,55,40], 'Norte':[60,75,50]}, index=['Café','Jugo','Chocolate'])
tabla.plot.bar()
plt.ylabel('Ventas'); plt.xticks(rotation=0); plt.show()
```



Ejemplo 3. Datos sintéticos de la historia.

RETO BREVE

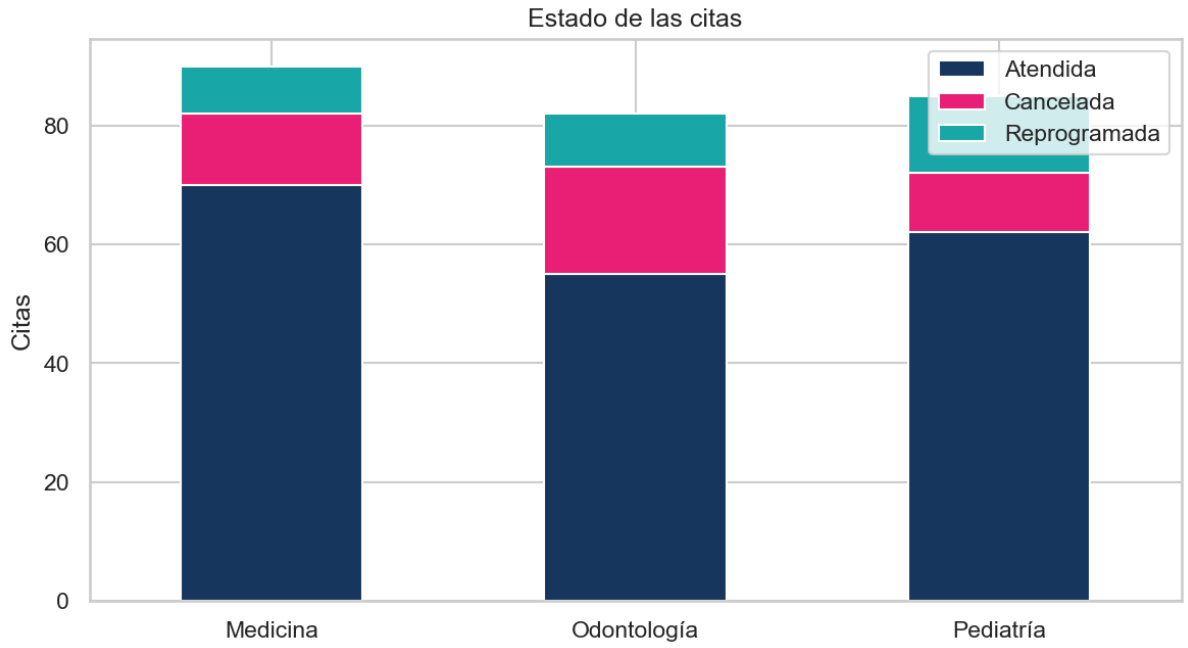
Identifique la bebida con mayor diferencia entre sedes.

04. Barras apiladas

HISTORIA	Un hospital revisa las citas de tres especialidades. Necesita ver el total de citas y cuántas fueron atendidas, canceladas o reprogramadas. Pregunta: ¿Qué especialidad tuvo más citas y cómo se distribuyeron?
Definición sencilla	Visualización para mostrar total y composición por categoría.
Objetivo	Mostrar total y composición por categoría.
Datos adecuados	Categoría principal, subcategoría y conteo.
Cuándo usarlo	Cuando interesa total y partes.
Cuándo evitarlo	Cuando se requiere comparar con precisión segmentos internos.
Ventaja	Resume composición y volumen.
Limitación	Solo el segmento inferior comparte línea base.
Ejemplo contextual	Estado de citas por especialidad.
Cómo interpretarlo	La altura total es el volumen; cada color representa una parte.
Errores frecuentes	Confundir cantidad con porcentaje.
Consejo de diseño	Ubique abajo la serie que desea comparar.

Código explicado

```
citas = pd.DataFrame({'Atendida':[70,55,62], 'Cancelada':[12,18,10], 'Reprogramada':[8,9,13]},
index=['Medicina','Odontología','Pediatría'])
citas.plot.bar(stacked=True)
plt.ylabel('Citas'); plt.show()
```



Ejemplo 4. Datos sintéticos de la historia.

RETO BREVE

Calcule visualmente el total de citas de Pediatría.

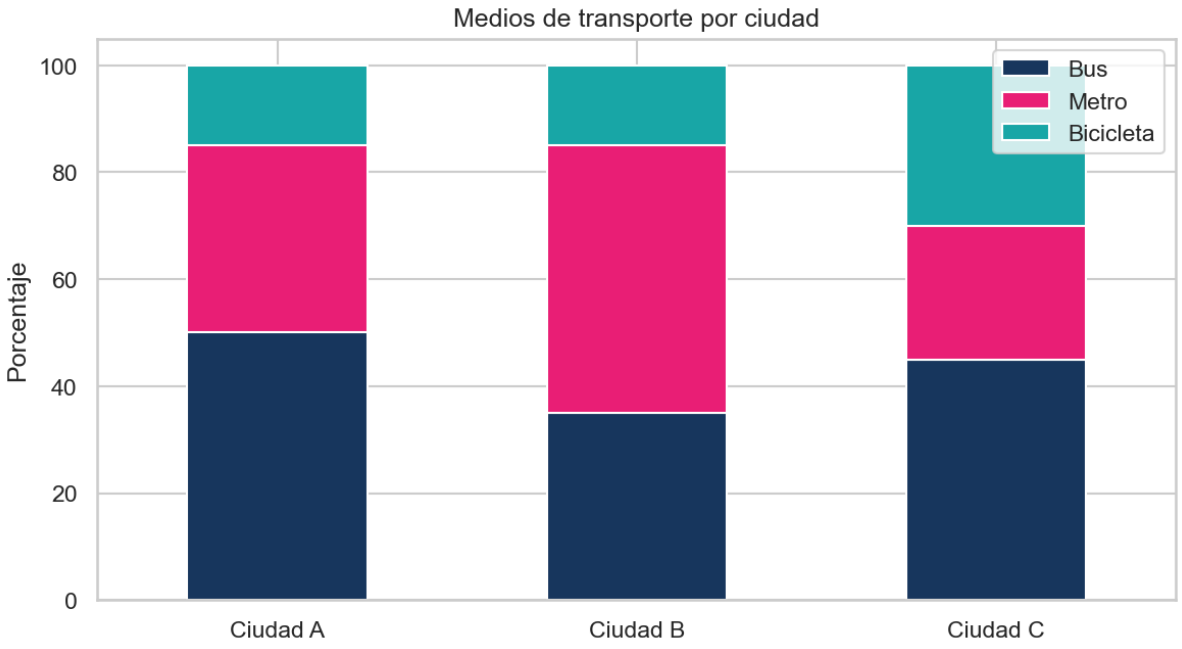
05. Barras apiladas al 100 %

HISTORIA	Tres ciudades usan bus, metro y bicicleta en cantidades diferentes. Para compararlas justamente se necesita observar el porcentaje de cada medio. Pregunta: ¿En qué ciudad tiene mayor participación la bicicleta?
Definición sencilla	Visualización para comparar proporciones entre grupos.
Objetivo	Comparar proporciones entre grupos.
Datos adecuados	Categoría, subcategoría y porcentaje.
Cuándo usarlo	Cuando los totales son distintos y preocupa la composición.
Cuándo evitarlo	Cuando el tamaño total es importante.
Ventaja	Todos los grupos comparten escala 0–100 %.
Limitación	Oculta diferencias de volumen.
Ejemplo contextual	Composición porcentual del transporte.
Cómo interpretarlo	Compare el ancho o altura de cada segmento, no el total.
Errores frecuentes	No aclarar que cada barra suma 100 %.

Consejo de diseño	Etiquete el eje y como porcentaje.

Código explicado

```
movilidad = pd.DataFrame({'Bus':[50,35,45], 'Metro':[35,50,25], 'Bicicleta':[15,15,30]}, index=['Ciudad
A','Ciudad B','Ciudad C'])
movilidad.plot.bar(stacked=True)
plt.ylabel('Porcentaje'); plt.show()
```



Ejemplo 5. Datos sintéticos de la historia.

RETO BREVE

Explique por qué todas las barras tienen la misma altura.

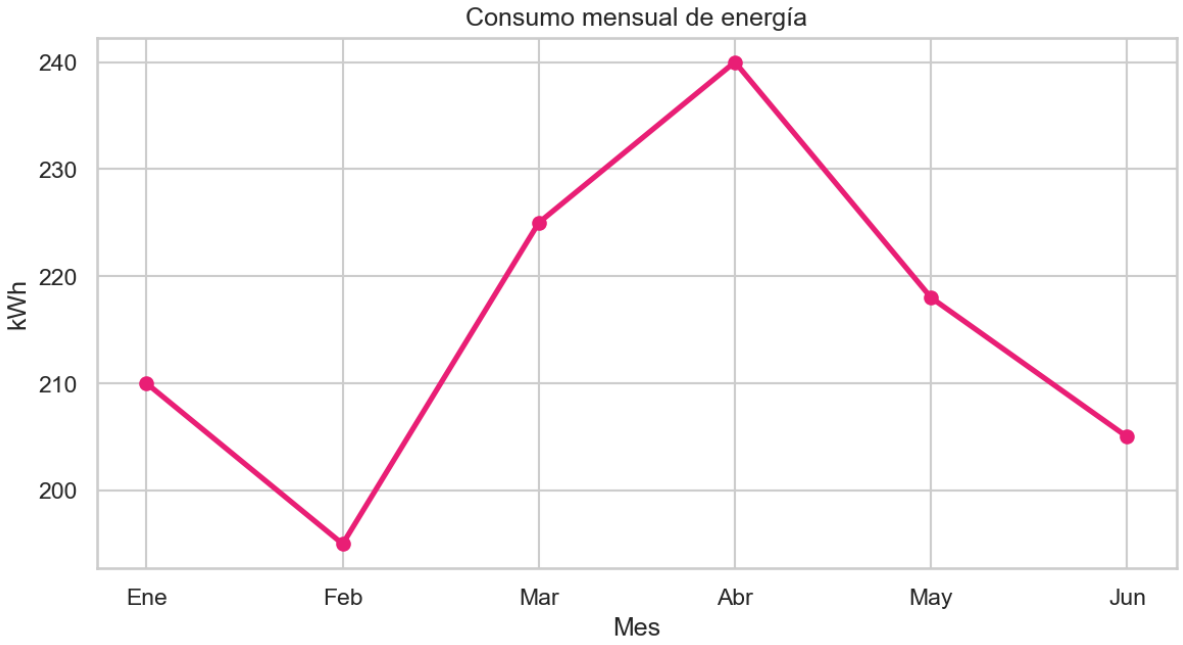
06. Gráfico de líneas

HISTORIA	Una familia registra el consumo de energía durante seis meses. Quiere saber si el consumo está aumentando o disminuyendo. Pregunta: ¿En qué mes se presentó el mayor consumo?
Definición sencilla	Visualización para mostrar evolución y tendencia en el tiempo.
Objetivo	Mostrar evolución y tendencia en el tiempo.
Datos adecuados	Fecha ordenada y medida numérica.
Cuándo usarlo	Cambios mensuales, semanales o diarios.
Cuándo evitarlo	Categorías sin orden natural.
Ventaja	Hace visible tendencia, picos y caídas.
Limitación	Muchas líneas producen ruido.
Ejemplo contextual	Consumo mensual de energía.
Cómo interpretarlo	Observe dirección, pendiente y puntos de giro.

Errores frecuentes	Fechas desordenadas o intervalos irregulares tratados como iguales.
Consejo de diseño	Ordene por fecha y no use suavizado que oculte los datos.

Código explicado

```
energia = pd.Series([210,195,225,240,218,205], index=['Ene','Feb','Mar','Abr','May','Jun'])
energia.plot(marker='o', color='#E91E75')
plt.ylabel('kWh'); plt.show()
```



Ejemplo 6. Datos sintéticos de la historia.

RETO BREVE

Describa la tendencia entre abril y junio.

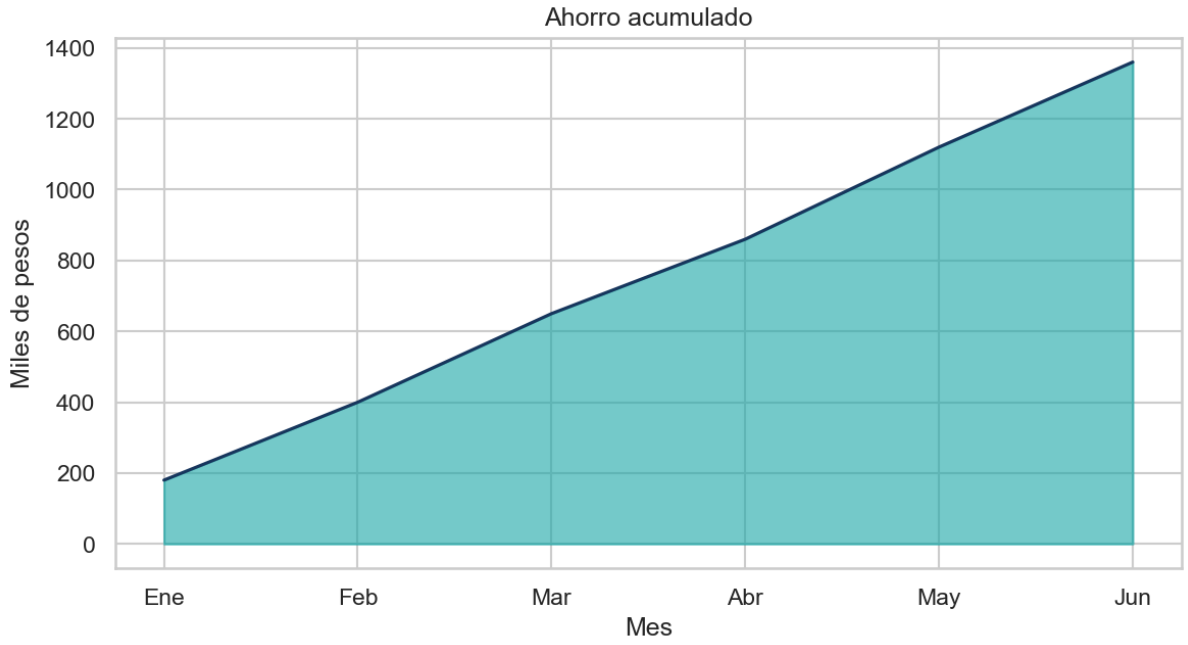
07. Gráfico de áreas

HISTORIA	Samuel ahorra una cantidad diferente cada mes para comprar un computador. Quiere observar cómo crece el dinero acumulado. Pregunta: ¿En qué mes superó un millón de pesos?
Definición sencilla	Visualización para resaltar magnitud o acumulación a través del tiempo.
Objetivo	Resaltar magnitud o acumulación a través del tiempo.
Datos adecuados	Tiempo y valor numérico.
Cuándo usarlo	Totales acumulados o volumen.
Cuándo evitarlo	Valores positivos y negativos superpuestos sin cuidado.
Ventaja	La masa visual comunica volumen.
Limitación	Menos preciso que una línea.
Ejemplo contextual	Ahorro acumulado por mes.
Cómo interpretarlo	Una pendiente mayor representa crecimiento más rápido.

Errores frecuentes	Usar área para datos no acumulables.
Consejo de diseño	Use transparencia y una línea de borde.

Código explicado

```
ahorro = pd.Series([180,220,250,210,260,240], index=['Ene','Feb','Mar','Abr','May','Jun']).cumsum()
plt.fill_between(ahorro.index, ahorro.values, alpha=.55)
plt.plot(ahorro.index, ahorro.values); plt.show()
```



Ejemplo 7. Datos sintéticos de la historia.

RETO BREVE

Agregue julio con un ahorro de 300 mil pesos.

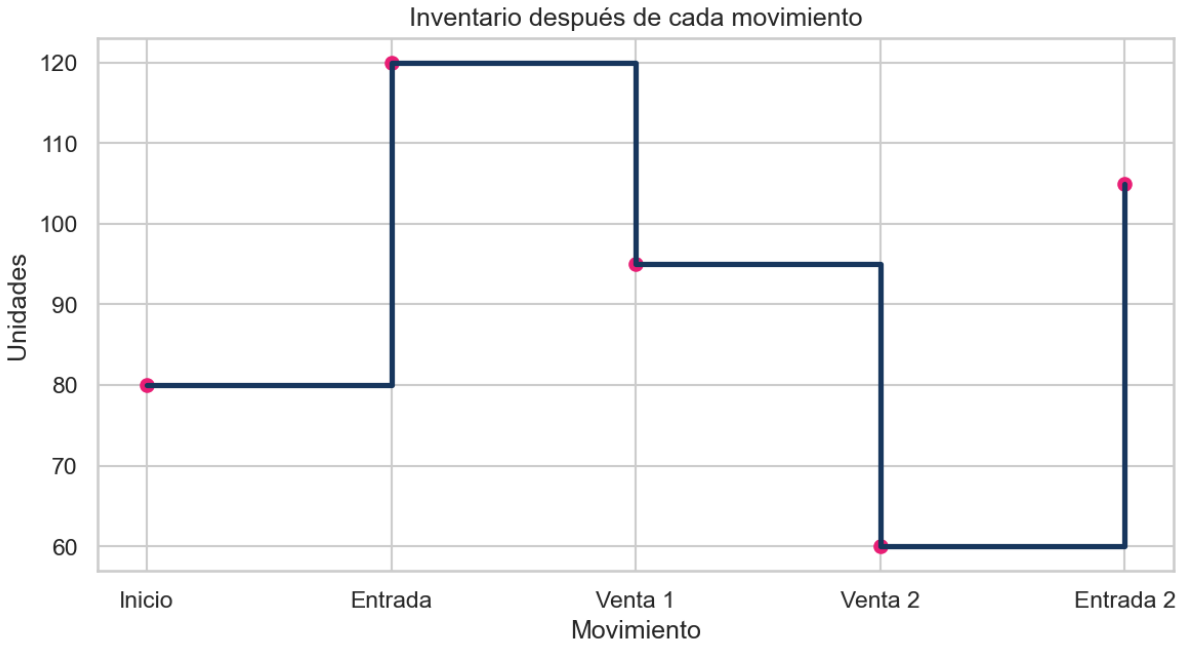
08. Gráfico escalonado

HISTORIA	Una bodega actualiza su inventario solo cuando recibe o despacha mercancía. Entre un movimiento y otro, la cantidad permanece igual. Pregunta: ¿Después de qué movimiento quedó menos inventario?
Definición sencilla	Visualización para mostrar cambios que ocurren por eventos o etapas.
Objetivo	Mostrar cambios que ocurren por eventos o etapas.
Datos adecuados	Tiempo o secuencia y valor.
Cuándo usarlo	Inventarios, tarifas o acumulados que cambian por saltos.
Cuándo evitarlo	Cambios continuos.
Ventaja	Distingue con claridad cada salto.
Limitación	Puede sugerir estabilidad entre observaciones.
Ejemplo contextual	Inventario después de cada movimiento.

Cómo interpretarlo	Cada tramo horizontal conserva el valor hasta el siguiente evento.
Errores frecuentes	Elegir mal `where` y desplazar visualmente el evento.
Consejo de diseño	Marque los puntos reales con símbolos.

Código explicado

```
movimientos = ['Inicio','Entrada','Venta 1','Venta 2','Entrada 2']
inventario = [80,120,95,60,105]
plt.step(movimientos, inventario, where='post')
plt.scatter(movimientos, inventario); plt.show()
```



Ejemplo 8. Datos sintéticos de la historia.

RETO BREVE

Agregue una venta final que deje 70 unidades.

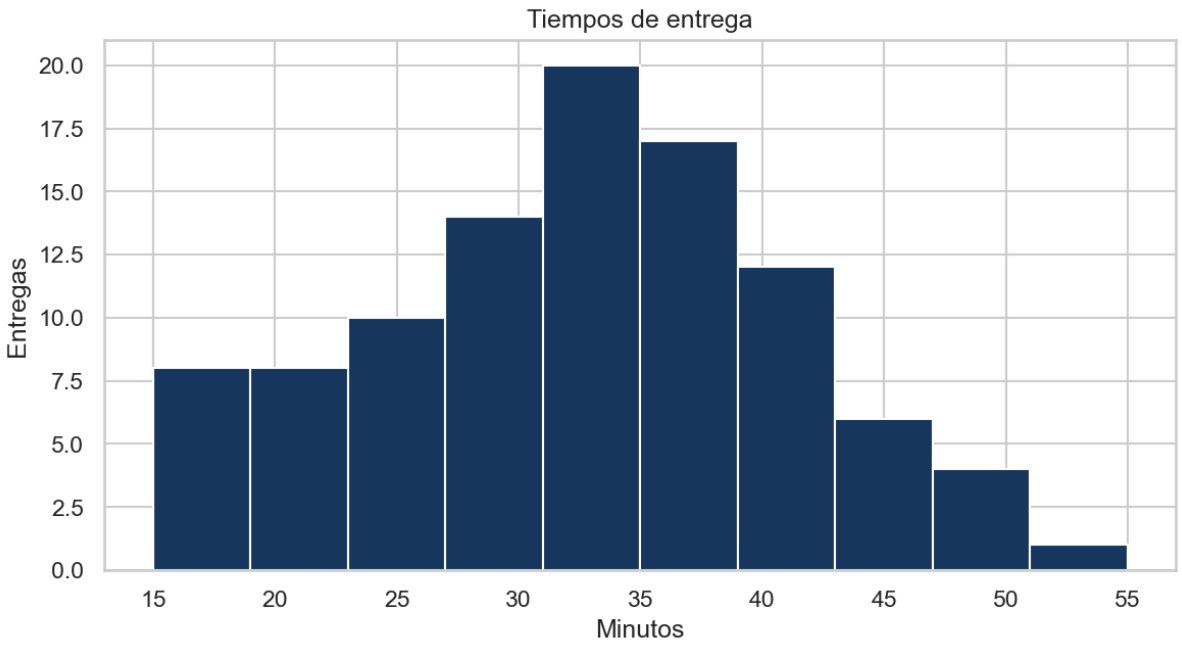
09. Histograma

HISTORIA	Una empresa de domicilios registró el tiempo de 100 entregas. El promedio no basta: necesita saber en qué intervalo se concentra la mayoría. Pregunta: ¿Cuál es el rango de tiempo más frecuente?
Definición sencilla	Visualización para comprender la distribución de una variable numérica.
Objetivo	Comprender la distribución de una variable numérica.
Datos adecuados	Variable cuantitativa continua o discreta con suficientes valores.
Cuándo usarlo	Forma, concentración, asimetría y posibles extremos.
Cuándo evitarlo	Categorías nominales.
Ventaja	Resume muchos registros.
Limitación	La forma cambia con el número de intervalos.

Ejemplo contextual	Distribución de tiempos de entrega.
Cómo interpretarlo	La altura representa cuántos valores caen en cada intervalo.
Errores frecuentes	Confundirlo con barras y elegir intervalos arbitrarios.
Consejo de diseño	Pruebe varios `bins` y explique la unidad.

Código explicado

```
tiempos = [18,22,24,25,27,28,30,30,31,32,33,34,35,36,38,40,42,45,48,52]
sns.histplot(tiempos, bins=6, color='#17365D')
plt.xlabel('Minutos'); plt.ylabel('Entregas'); plt.show()
```



Ejemplo 9. Datos sintéticos de la historia.

RETO BREVE

Compare el resultado utilizando 5 y 10 intervalos.

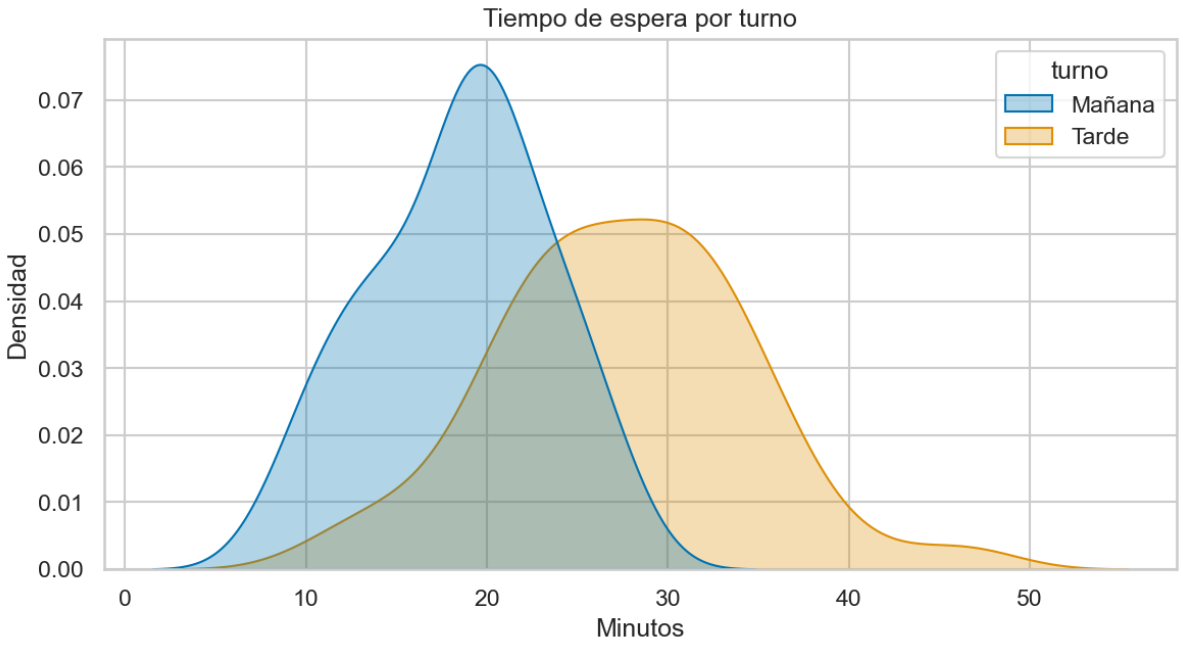
10. Curva de densidad (KDE)

HISTORIA	Una clínica compara los tiempos de espera de los turnos de mañana y tarde. Quiere identificar dónde se concentra cada grupo. Pregunta: ¿En qué turno tienden a ser menores los tiempos de espera?
Definición sencilla	Visualización para estimar suavemente la forma de una distribución.
Objetivo	Estimar suavemente la forma de una distribución.
Datos adecuados	Variable cuantitativa continua.
Cuándo usarlo	Comparar formas entre pocos grupos.
Cuándo evitarlo	Muestras muy pequeñas o datos estrictamente discretos.
Ventaja	Facilita comparar distribuciones superpuestas.

Limitación	El suavizado puede inventar apariencia entre datos.
Ejemplo contextual	Densidad de espera por turno.
Cómo interpretarlo	Los picos muestran zonas de mayor concentración, no cantidades directas.
Errores frecuentes	Leer el eje y como número de estudiantes.
Consejo de diseño	Acompáñe con tamaños de muestra o histograma.

Código explicado

```
esperas = pd.DataFrame({'minutos':[10,12,14,16,18,20,22,24,26,28,18,21,24,27,30,32,35,38,40,44],
'turno':['Mañana']*10+['Tarde']*10})
sns.kdeplot(data=esperas, x='minutos', hue='turno', fill=True, common_norm=False)
plt.show()
```



Ejemplo 10. Datos sintéticos de la historia.

RETO BREVE

Señale el pico principal de cada turno.

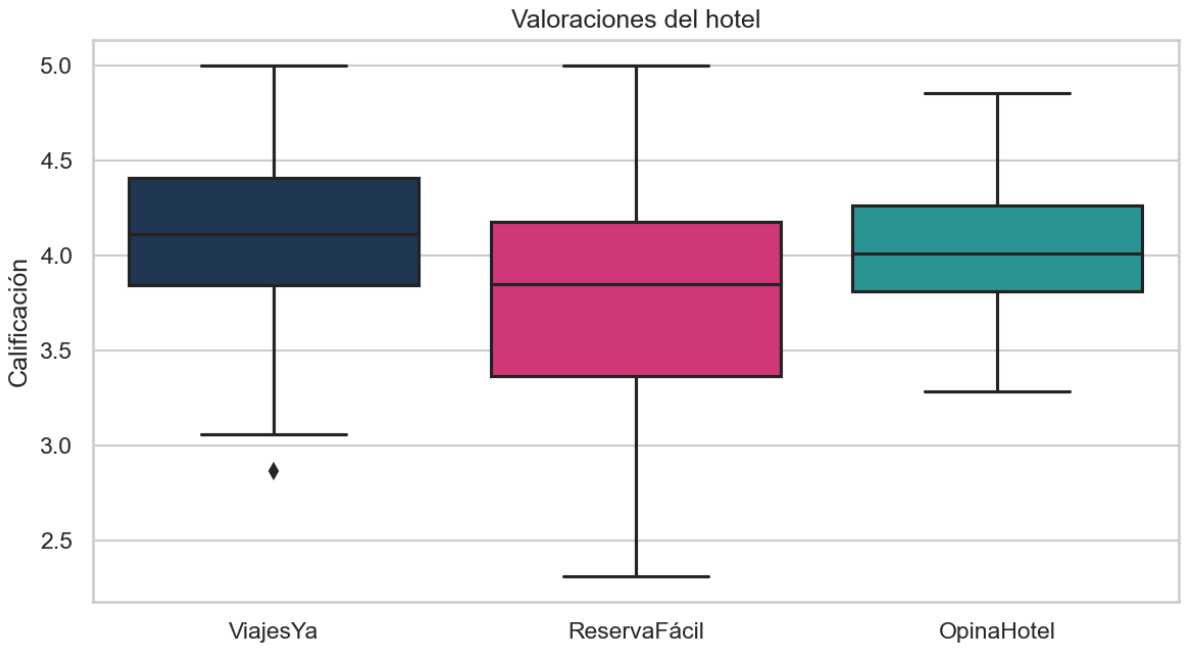
11. Diagrama de caja

HISTORIA	Un hotel recibe calificaciones desde tres plataformas. La gerencia quiere comparar la mediana, la variación y las opiniones extremas. Pregunta: ¿Qué plataforma presenta valoraciones más consistentes?
Definición sencilla	Visualización para comparar mediana, dispersión y valores atípicos.
Objetivo	Comparar mediana, dispersión y valores atípicos.
Datos adecuados	Variable numérica por grupo.
Cuándo usarlo	Comparar distribuciones de varias categorías.
Cuándo evitarlo	Cuando el público necesita ver cada observación y la muestra es pequeña.

Ventaja	Resumen compacto y resistente a extremos.
Limitación	No muestra toda la forma de la distribución.
Ejemplo contextual	Calificaciones del hotel por plataforma.
Cómo interpretarlo	La línea es la mediana; la caja contiene el 50 % central.
Errores frecuentes	Eliminar automáticamente puntos atípicos.
Consejo de diseño	Explique cuartiles antes de interpretar.

Código explicado

```
opiniones = pd.DataFrame({'plataforma':['A']*6+['B']*6+['C']*6, 'calificacion':[4.1,4.2,4.3,4.4,4.5,4.6,
2.9,3.4,3.8,4.0,4.4,4.8, 3.8,3.9,4.0,4.1,4.2,4.3]})
sns.boxplot(data=opiniones, x='plataforma', y='calificacion')
plt.show()
```



Ejemplo 11. Datos sintéticos de la historia.

RETO BREVE

Identifique la plataforma con la caja más pequeña.

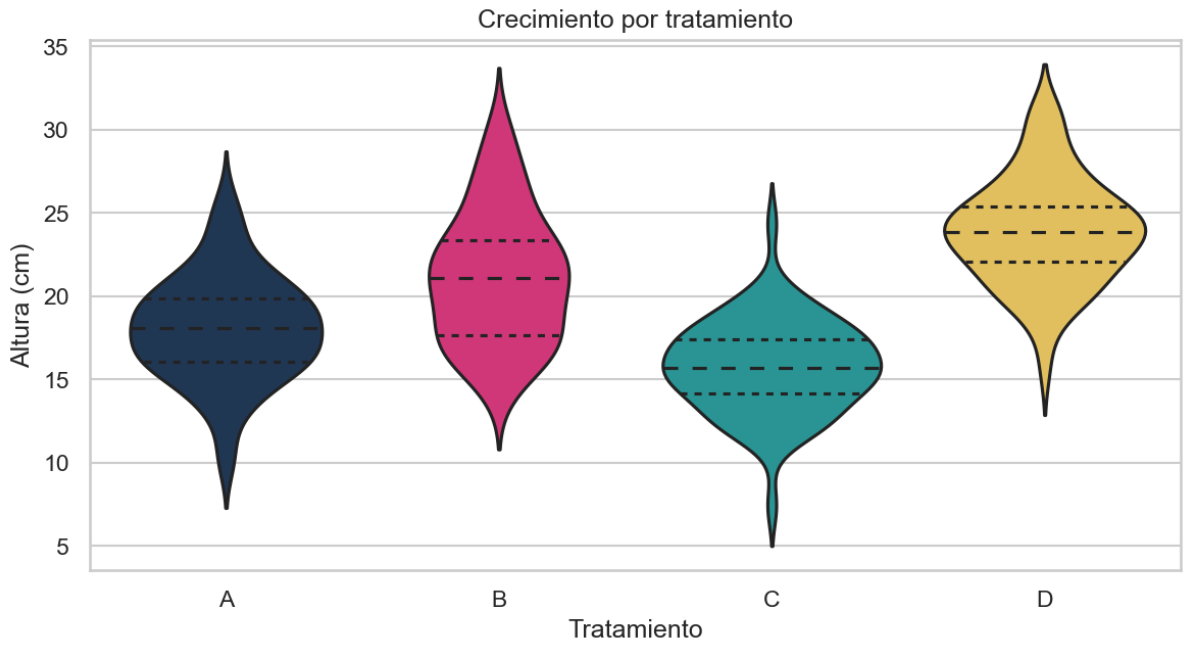
12. Diagrama de violín

HISTORIA	Un vivero prueba cuatro tratamientos para una planta. Además del promedio, quiere observar si el crecimiento se concentra en uno o varios niveles. Pregunta: ¿Qué tratamiento muestra mayor concentración de plantas altas?
Definición sencilla	Visualización para comparar distribución, densidad y posición por grupos.
Objetivo	Comparar distribución, densidad y posición por grupos.
Datos adecuados	Variable numérica y categoría.
Cuándo usarlo	Cuando la forma interna importa.

Cuándo evitarlo	Audiencias sin introducción estadística o muestras pequeñas.
Ventaja	Revela multimodalidad que la caja puede ocultar.
Limitación	El ancho es una estimación suavizada.
Ejemplo contextual	Distribución del crecimiento por tratamiento.
Cómo interpretarlo	Las zonas anchas indican mayor densidad de observaciones.
Errores frecuentes	Creer que un violín más ancho contiene necesariamente más registros.
Consejo de diseño	Muestre cuartiles y reporte `n`.

Código explicado

```
plantas = pd.DataFrame({'tratamiento':list('AAAAAAAABBBBBBBBCCCCCCCCDDDDDDDD'),
'altura':[14,15,16,17,18,18,19,20, 17,18,19,20,21,22,23,24, 12,13,14,15,15,16,17,18, 20,21,22,23,24,25,26,27]})
sns.violinplot(data=plantas, x='tratamiento', y='altura', inner='quartile')
plt.show()
```



Ejemplo 12. Datos sintéticos de la historia.

RETO BREVE

Compare la forma del tratamiento A con el D.

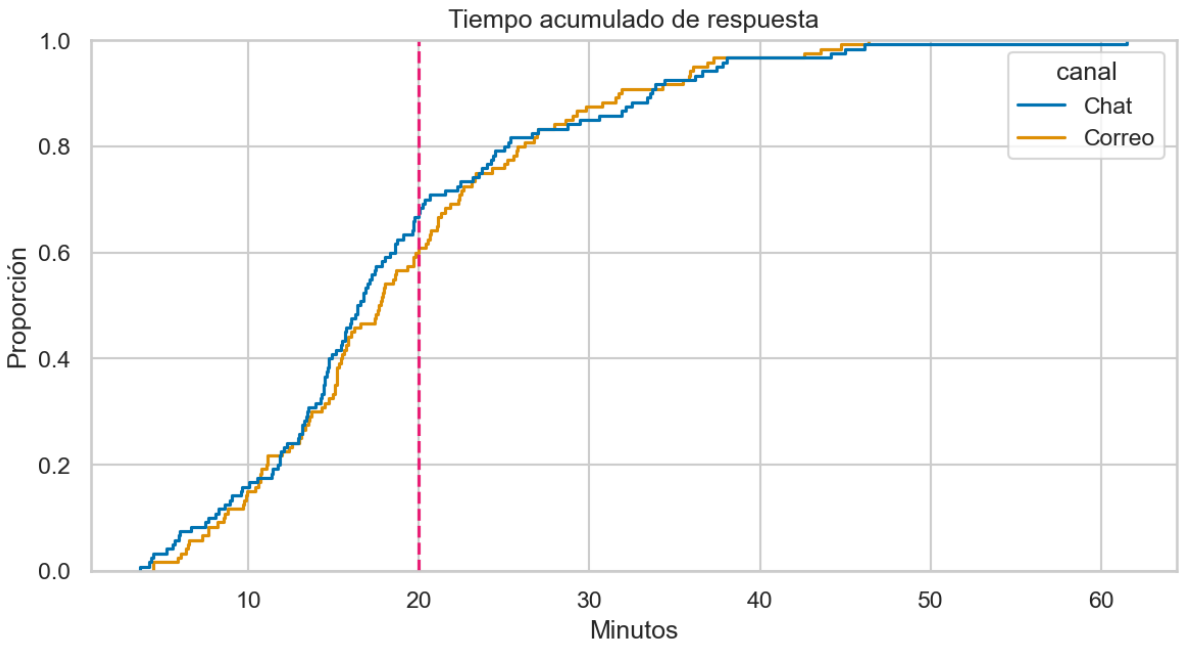
13. ECDF

HISTORIA	Un centro de soporte mide cuánto tarda en responder. La jefa necesita saber qué porcentaje de solicitudes fue atendido en 20 minutos o menos. Pregunta: ¿Qué proporción cumple el límite de 20 minutos?
Definición sencilla	Visualización para mostrar la proporción de observaciones menor o igual a cada valor.
Objetivo	Mostrar la proporción de observaciones menor o igual a cada valor.
Datos adecuados	Variable numérica.

Cuándo usarlo	Comparar distribuciones sin escoger intervalos.
Cuándo evitarlo	Presentaciones muy introductorias sin explicar acumulación.
Ventaja	No depende de `bins` ni suavizado.
Limitación	Su lectura inicial es menos intuitiva.
Ejemplo contextual	Proporción acumulada del tiempo de respuesta.
Cómo interpretarlo	Busque x=3 y lea la altura acumulada.
Errores frecuentes	Confundir proporción acumulada con frecuencia simple.
Consejo de diseño	Agregue líneas de referencia para responder preguntas.

Código explicado

```
soporte = pd.DataFrame({'minutos':[5,8,10,12,15,18,22,25,30,35, 8,12,16,20,24,28,32,36,40,45],
'canal':['Chat']*10+['Correo']*10})
sns.ecdfplot(data=soporte, x='minutos', hue='canal')
plt.axvline(20, color='red', linestyle='--'); plt.show()
```



Ejemplo 13. Datos sintéticos de la historia.

RETO BREVE

Lea también el porcentaje atendido en 30 minutos.

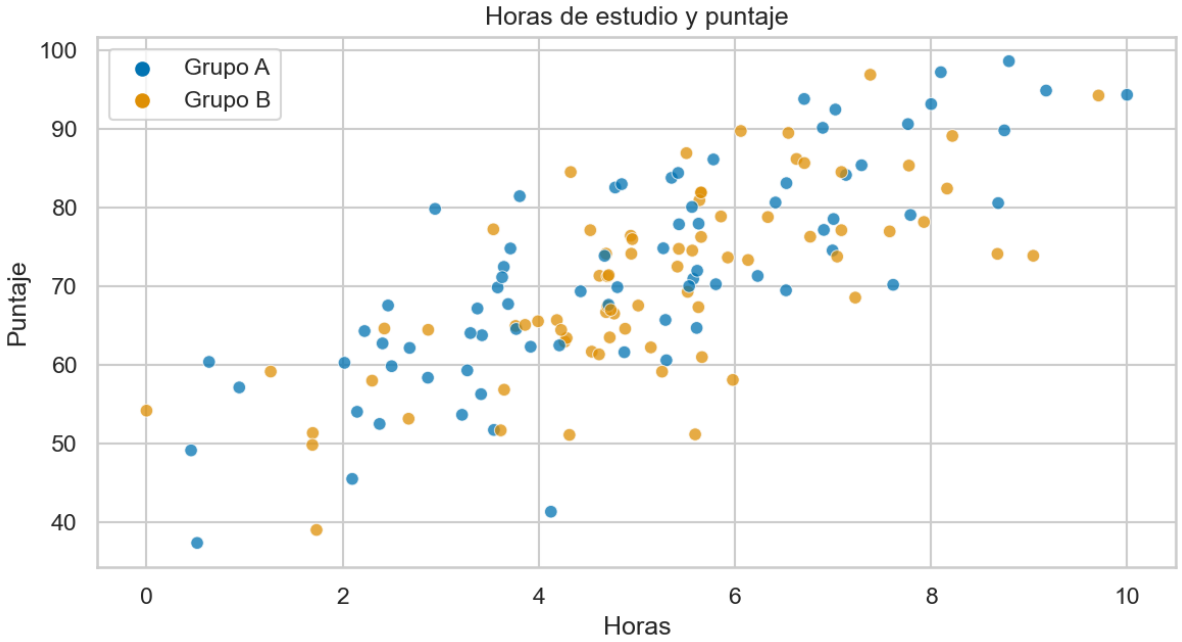
14. Diagrama de dispersión

HISTORIA	Una docente quiere explorar si estudiar más horas se relaciona con un mejor resultado. Cada punto representa un estudiante. Pregunta: ¿Existe una relación visible entre horas de estudio y puntaje?
Definición sencilla	Visualización para explorar relación entre dos variables numéricas.
Objetivo	Explorar relación entre dos variables numéricas.

Datos adecuados	Dos medidas por observación; color opcional por categoría.
Cuándo usarlo	Correlación, patrones, grupos y valores atípicos.
Cuándo evitarlo	Una variable categórica como eje continuo.
Ventaja	Conserva el detalle de cada registro.
Limitación	La superposición oculta puntos.
Ejemplo contextual	Horas de estudio frente al puntaje.
Cómo interpretarlo	Observe dirección, fuerza, forma y excepciones; correlación no implica causalidad.
Errores frecuentes	Afirmar causalidad o ajustar una línea sin revisar valores atípicos.
Consejo de diseño	Use transparencia y unidades claras.

Código explicado

```
estudio = pd.DataFrame({'horas':[1,2,2,3,4,5,5,6,7,8,9], 'puntaje':[48,55,52,61,66,70,74,78,82,88,92],
'grupo':['A','A','B','A','B','A','B','A','B','A','B']})
sns.scatterplot(data=estudio, x='horas', y='puntaje', hue='grupo')
plt.show()
```



Ejemplo 14. Datos sintéticos de la historia.

RETO BREVE

Describa la dirección de la relación sin afirmar causalidad.

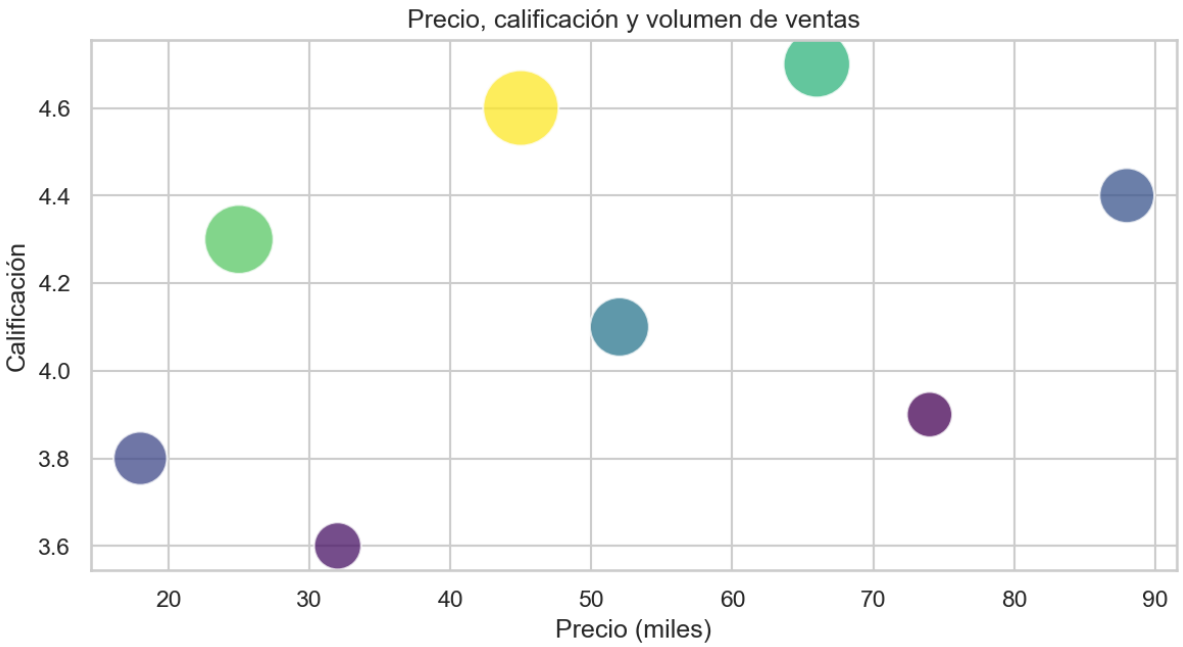
15. Gráfico de burbujas

HISTORIA	Una tienda analiza sus productos con precio, calificación y número de ventas. Quiere encontrar productos bien valorados y con alta demanda. Pregunta: ¿Qué productos combinan buena calificación y muchas ventas?
Definición sencilla	Visualización para relacionar dos medidas incorporando tamaño y color.

Objetivo	Relacionar dos medidas incorporando tamaño y color.
Datos adecuados	Dos ejes numéricos + tamaño + color opcional.
Cuándo usarlo	Resumen multivariable de pocas entidades.
Cuándo evitarlo	Muchos puntos o tamaños muy parecidos.
Ventaja	Integra hasta cuatro variables.
Limitación	El área es difícil de comparar con precisión.
Ejemplo contextual	Precio, calificación y volumen de ventas.
Cómo interpretarlo	Lea primero los ejes; luego use tamaño y color como contexto.
Errores frecuentes	Mapear radios en vez de áreas o no explicar el tamaño.
Consejo de diseño	Incluya leyenda de tamaños y reduzca el número de burbujas.

Código explicado

```
productos = pd.DataFrame({'precio':[18,25,32,45,52,66], 'calificacion':[3.8,4.3,3.6,4.6,4.1,4.7],
'ventas':[90,150,70,180,110,140]})
plt.scatter(productos['precio'], productos['calificacion'], s=productos['ventas']*8, alpha=.7)
plt.xlabel('Precio'); plt.ylabel('Calificación'); plt.show()
```



Ejemplo 15. Datos sintéticos de la historia.

RETO BREVE

Explique qué representa el tamaño de cada burbuja.

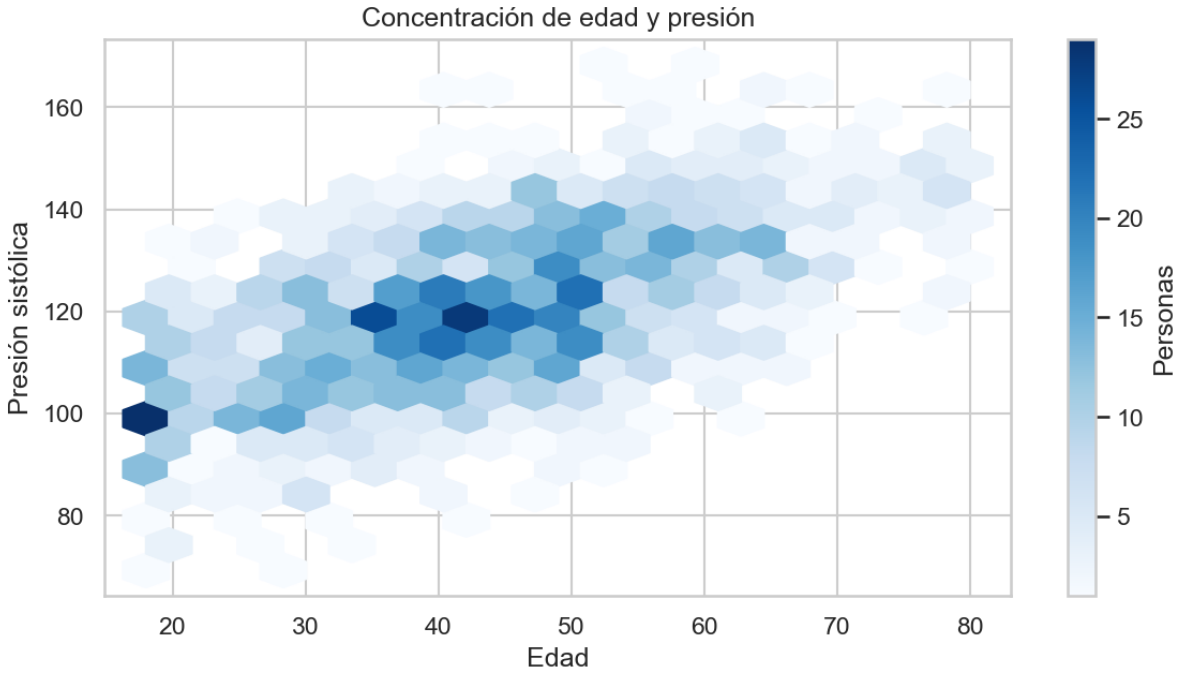
16. Hexbin

HISTORIA	Una campaña de salud tiene miles de mediciones de edad y presión arterial. Los puntos se superponen y se necesita mostrar las zonas de mayor concentración. Pregunta: ¿En qué combinación de edad y presión se concentran más personas?

Definición sencilla	Visualización para mostrar concentración cuando hay muchos puntos.
Objetivo	Mostrar concentración cuando hay muchos puntos.
Datos adecuados	Dos variables numéricas con alta densidad.
Cuándo usarlo	Dispersión con fuerte superposición.
Cuándo evitarlo	Pocos registros.
Ventaja	Resume densidad local.
Limitación	Oculta observaciones individuales.
Ejemplo contextual	Concentración de edad y presión.
Cómo interpretarlo	Los hexágonos más intensos contienen más observaciones.
Errores frecuentes	No incluir barra de color o usar una cuadrícula demasiado fina.
Consejo de diseño	Ajuste `gridsize` al tamaño de la muestra.

Código explicado

```
import numpy as np
rng = np.random.default_rng(7)
edad = rng.normal(43, 15, 800)
presion = 92 + 0.65*edad + rng.normal(0, 13, 800)
plt.hexbin(edad, presion, gridsize=15, cmap='Blues', mincnt=1)
plt.colorbar(label='Personas'); plt.show()
```



Ejemplo 16. Datos sintéticos de la historia.

RETO BREVE

Explique qué significa un hexágono más oscuro.

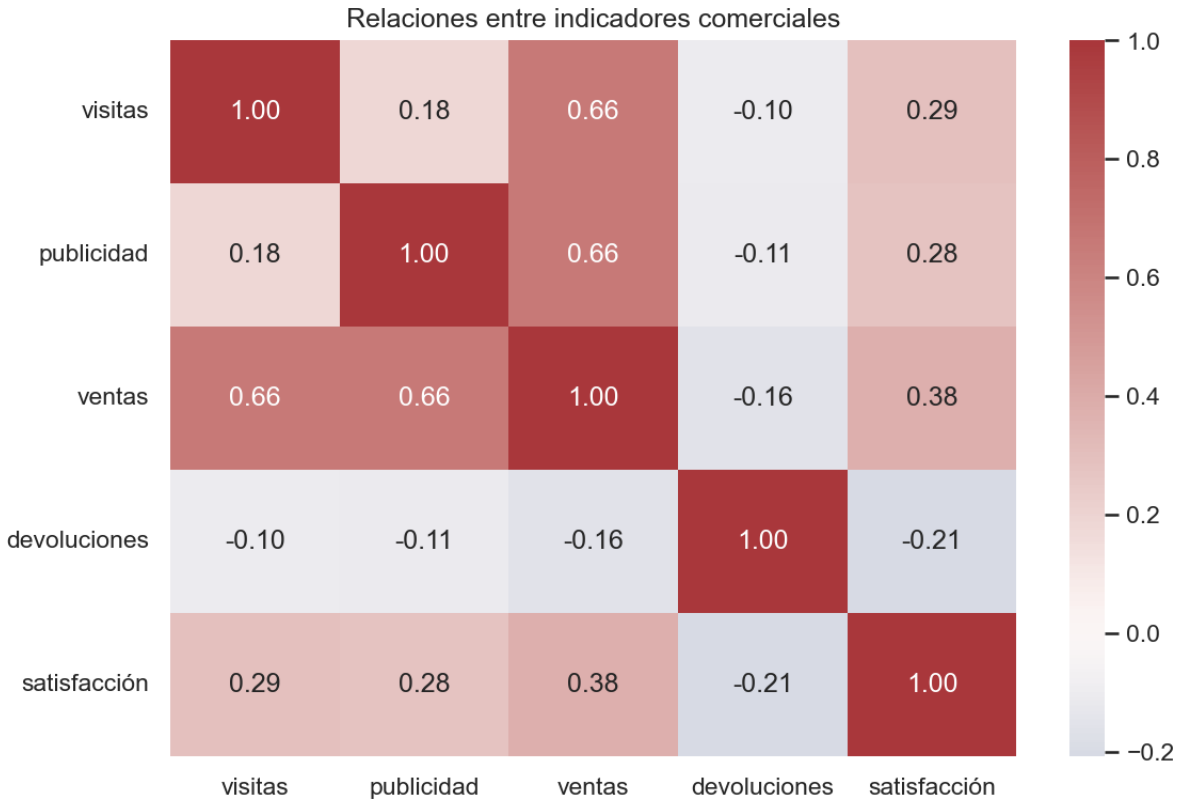
17. Mapa de calor

HISTORIA	Una tienda desea descubrir qué indicadores se relacionan:

	visitas, publicidad, ventas, devoluciones y satisfacción. Necesita revisar todos los pares. Pregunta: ¿Cuáles indicadores presentan la relación más fuerte?
Definición sencilla	Visualización para comparar una matriz mediante intensidad de color.
Objetivo	Comparar una matriz mediante intensidad de color.
Datos adecuados	Tabla de valores o matriz de correlación.
Cuándo usarlo	Patrones en muchas combinaciones.
Cuándo evitarlo	Cuando el valor exacto es la única prioridad.
Ventaja	Detecta patrones globales rápidamente.
Limitación	El color puede exagerar diferencias pequeñas.
Ejemplo contextual	Correlación entre indicadores comerciales.
Cómo interpretarlo	Valores cercanos a 1 o -1 indican asociación lineal fuerte; no causalidad.
Errores frecuentes	Incluir identificadores o interpretar correlación como causa.
Consejo de diseño	Use una paleta divergente centrada en cero.

Código explicado

```
indicadores = pd.DataFrame({'visitas':[80,95,110,125,140,155], 'publicidad':[10,14,13,19,22,25],
'ventas':[30,38,44,58,66,75], 'devoluciones':[8,7,7,5,4,3], 'satisfaccion':[3.2,3.4,3.6,4.0,4.2,4.5]})
sns.heatmap(indicadores.corr(), annot=True, cmap='vlag', center=0)
plt.show()
```



Ejemplo 17. Datos sintéticos de la historia.

RETO BREVE

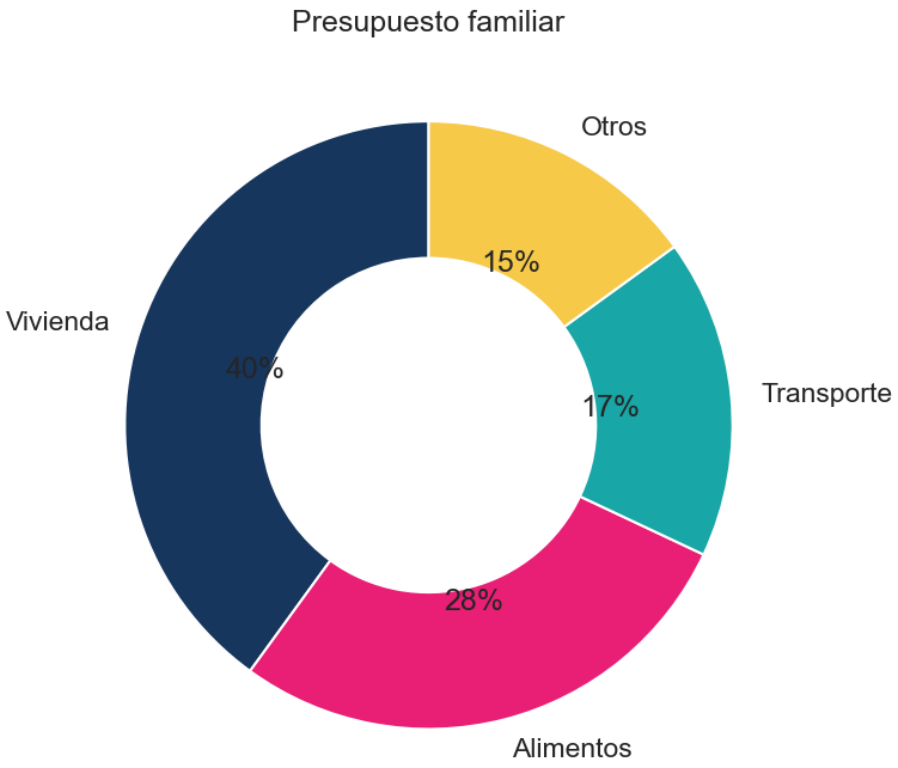
Encuentre la relación positiva y la negativa más fuertes.

18. Gráfico de dona

HISTORIA	Una familia quiere revisar en qué utiliza su presupuesto mensual. Solo necesita comparar vivienda, alimentación, transporte y otros gastos. Pregunta: ¿Qué categoría ocupa la mayor parte del presupuesto?
Definición sencilla	Visualización para mostrar composición simple de un total.
Objetivo	Mostrar composición simple de un total.
Datos adecuados	Una categoría con 2–5 partes.
Cuándo usarlo	Participaciones muy diferenciadas y pocas categorías.
Cuándo evitarlo	Muchas partes o diferencias pequeñas.
Ventaja	Comunicación rápida de proporciones.
Limitación	Los ángulos se comparan peor que las longitudes.
Ejemplo contextual	Distribución del presupuesto familiar.
Cómo interpretarlo	Todas las porciones deben sumar 100 %.
Errores frecuentes	Efectos 3D, demasiadas porciones o porcentajes que no suman.
Consejo de diseño	Prefiera barras cuando necesite precisión.

Código explicado

```
gastos = pd.Series({'Vivienda':40,'Alimentos':28,'Transporte':17,'Otros':15})
plt.pie(gastos, labels=gastos.index, autopct='%1.0f%%', wedgeprops={'width':.45})
plt.show()
```



Ejemplo 18. Datos sintéticos de la historia.

RETO BREVE

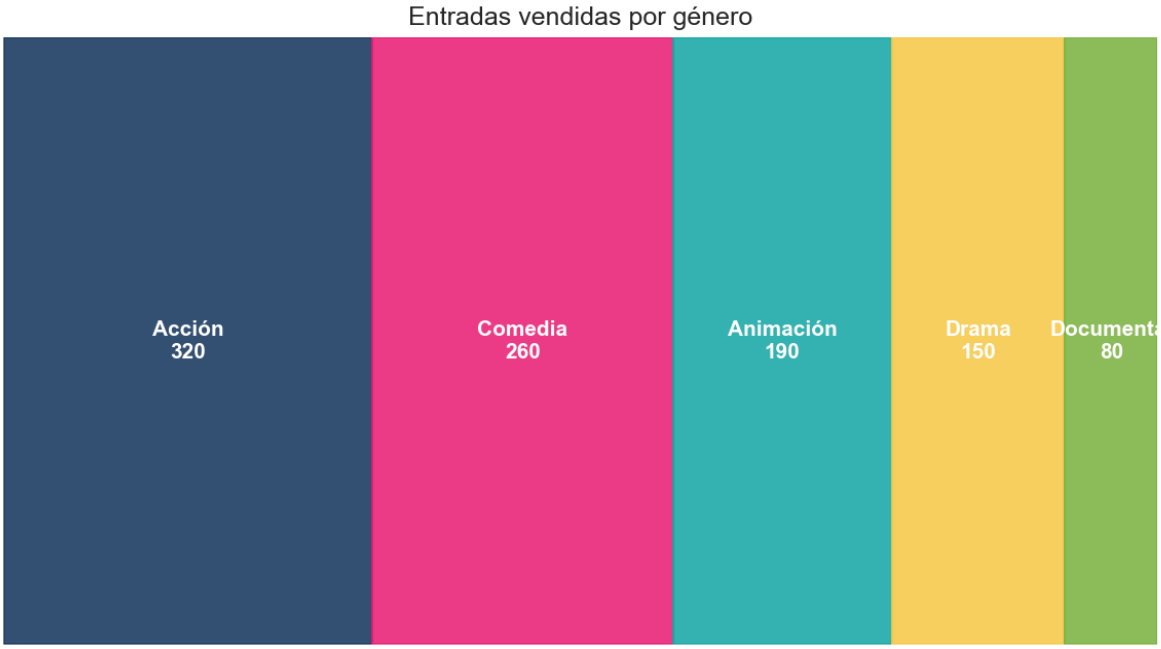
Compruebe que las cuatro porciones suman 100 %.

19. Treemap

HISTORIA	Un cine quiere resumir la venta de entradas por género. Desea que el espacio ocupado permita reconocer rápidamente los géneros más populares. Pregunta: ¿Qué género representa la mayor parte de las entradas?
Definición sencilla	Visualización para mostrar jerarquía o participación mediante áreas.
Objetivo	Mostrar jerarquía o participación mediante áreas.
Datos adecuados	Categorías con valor y jerarquía opcional.
Cuándo usarlo	Composición con más partes que un pastel.
Cuándo evitarlo	Comparaciones exactas entre áreas similares.
Ventaja	Aprovecha bien el espacio.
Limitación	Las áreas son difíciles de estimar.
Ejemplo contextual	Entradas vendidas por género.
Cómo interpretarlo	Un rectángulo mayor representa una participación mayor.
Errores frecuentes	Usarlo como ranking exacto o saturar de etiquetas.
Consejo de diseño	Agrupe categorías pequeñas en 'Otros'.

Código explicado

```
import squarify
entradas = pd.Series({'Acción':320,'Comedia':260,'Animación':190,'Drama':150,'Documental':80})
squarify.plot(sizes=entradas.values, label=entradas.index, alpha=.8)
plt.axis('off'); plt.show()
```



Ejemplo 19. Datos sintéticos de la historia.

RETO BREVE

Ordene los géneros de mayor a menor usando el área.

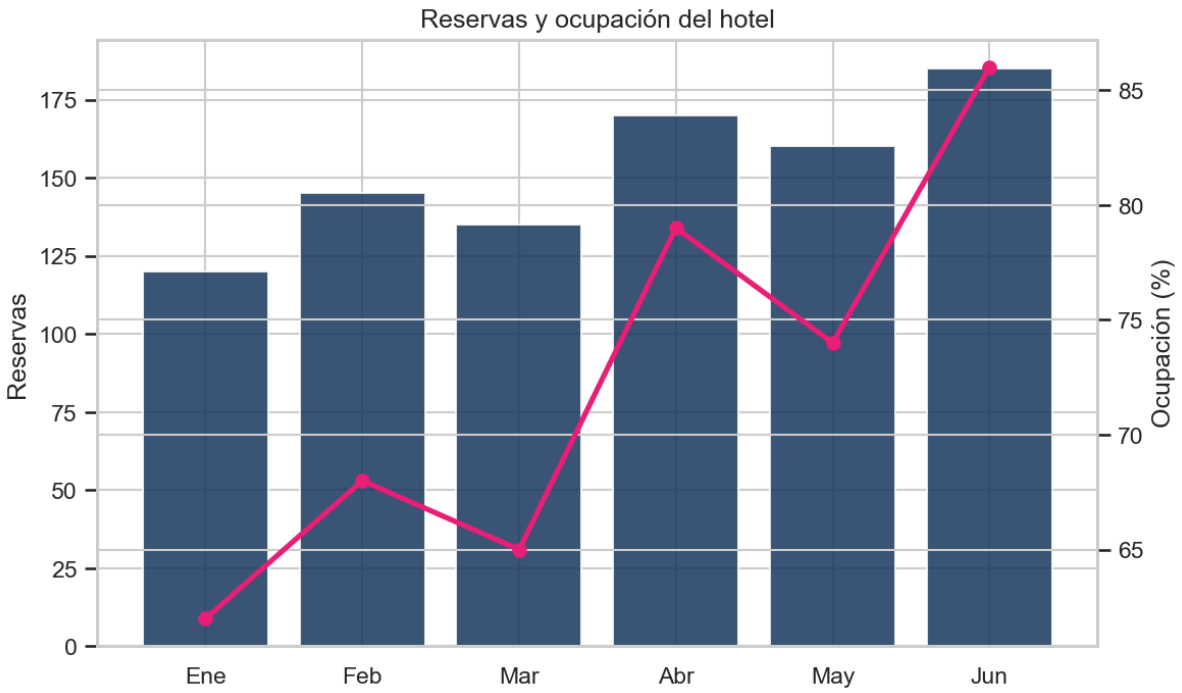
20. Gráfico combinado

HISTORIA	Un hotel compara el número de reservas con el porcentaje de ocupación mensual. Muchas reservas no siempre significan el mismo nivel de ocupación. Pregunta: ¿En qué mes coinciden más reservas y mayor ocupación?
Definición sencilla	Visualización para contrastar dos medidas relacionadas en una misma vista.
Objetivo	Contrastar dos medidas relacionadas en una misma vista.
Datos adecuados	Una categoría o tiempo y dos medidas.
Cuándo usarlo	Volumen con tasa, presupuesto con cumplimiento.
Cuándo evitarlo	Unidades sin relación o demasiadas series.
Ventaja	Conecta cantidad y desempeño.
Limitación	El doble eje puede inducir conclusiones engañosas.
Ejemplo contextual	Reservas y ocupación mensual.
Cómo interpretarlo	Lea cada serie con su eje y compare patrones, no alturas directas.
Errores frecuentes	Manipular escalas para fabricar correlación.

Consejo de diseño Etiquete ejes con colores coherentes y declare ambas unidades.

Código explicado

```
meses = ['Ene','Feb','Mar','Abr','May','Jun']
reservas = [120,145,135,170,160,185]
ocupacion = [62,68,65,79,74,86]
fig, ax1 = plt.subplots()
ax1.bar(meses, reservas, color='#17365D')
ax2 = ax1.twinx(); ax2.plot(meses, ocupacion, color='#E91E75', marker='o')
plt.show()
```



Ejemplo 20. Datos sintéticos de la historia.

RETO BREVE

Explique por qué cada serie necesita un eje diferente.

6. Proyecto integrador

RETO: construir una historia visual del centro de formación

La coordinación necesita decidir qué cursos fortalecer y dónde acompañar a los estudiantes. Usted recibirá datos sintéticos de estudiantes, cursos e inscripciones. Debe preparar un reporte visual reproducible.

Preguntas del proyecto

1. ¿Cuáles son los cinco cursos con más matrículas?

2. ¿Cómo evolucionan las matrículas por mes?

3. ¿Cómo se distribuyen las notas y el progreso?

4. ¿Qué relación existe entre progreso y nota?

5. ¿Cómo cambia la aprobación por curso y modalidad?

6. ¿Qué valores atípicos requieren revisión?

7. ¿Qué tres recomendaciones puede sustentar con evidencia?

Ruta guiada para construir las respuestas

Después de cargar `df` mediante CSV o SQLite, ejecute estos bloques en orden. Cada resumen alimenta una visualización y puede reutilizarse en la conclusión.

Paso 1. Comparar la demanda y observar el tiempo

```
# 1. Top 5 de cursos
top5 = df['curso'].value_counts().nlargest(5).sort_values()
top5.plot.barh(color='#17365D', title='Cinco cursos con más matrículas')
plt.xlabel('Matrículas'); plt.tight_layout(); plt.show()

# 2. Evolución mensual
mensual = df.groupby(df['fecha'].dt.to_period('M')).size()
mensual.index = mensual.index.astype(str)
mensual.plot(marker='o', color='#E91E75', title='Matrículas por mes')
plt.ylabel('Matrículas'); plt.tight_layout(); plt.show()
```

Paso 2. Estudiar distribuciones y relaciones

```
# 3. Distribución de notas y progreso
fig, ejes = plt.subplots(1, 2, figsize=(10, 4))
sns.histplot(data=df, x='nota', bins=12, ax=ejes[0])
sns.histplot(data=df, x='progreso', bins=12, ax=ejes[1])
ejes[0].set_title('Distribución de notas')
ejes[1].set_title('Distribución del progreso')
plt.tight_layout(); plt.show()

# 4. Relación entre progreso y nota
sns.scatterplot(data=df, x='progreso', y='nota', hue='estado', alpha=.75)
plt.title('Progreso y nota'); plt.tight_layout(); plt.show()
```

Paso 3. Calcular aprobación y revisar valores atípicos

```
# 5. Aprobación por curso y modalidad
aprobacion = (df.groupby(['curso', 'modalidad'])['aprobado']
                .mean().mul(100).reset_index(name='tasa_aprobacion'))
sns.barplot(data=aprobacion, x='curso', y='tasa_aprobacion', hue='modalidad')
plt.ylabel('Aprobación (%)'); plt.xticks(rotation=35, ha='right')
plt.tight_layout(); plt.show()

# 6. Posibles valores atípicos de nota mediante el rango intercuartílico
q1, q3 = df['nota'].quantile([0.25, 0.75])
iqr = q3 - q1
atipicos = df[(df['nota'] < q1 - 1.5*iqr) | (df['nota'] > q3 + 1.5*iqr)]
print(atipicos[['nombre', 'curso', 'nota', 'progreso']])
sns.boxplot(data=df, x='nota'); plt.title('Revisión de notas atípicas'); plt.show()
```

Paso 4. Crear el archivo HTML interactivo

```
# 7. Gráfico interactivo y exportación a HTML
fig = px.scatter(df, x='progreso', y='nota', color='estado',
                 hover_data=['nombre', 'curso', 'modalidad'],
                 title='Progreso y nota por estudiante')
fig.write_html(GRAFICOS / 'reporte_interactivo.html')
fig.show()
```

Para redactar cada conclusión utilice esta estructura: hallazgo observable + cifra que lo respalda + posible decisión. Evite afirmar causas que los datos no demuestran.

Entregables

- Un script `.py` o cuaderno `.ipynb` ejecutable.
- Mínimo seis gráficos de cuatro familias distintas.
- Una versión corregida de un gráfico engañoso.
- Un reporte HTML interactivo de Plotly.
- Una conclusión breve debajo de cada gráfico: hallazgo + evidencia + posible decisión.

Criterios de calidad

- Pregunta clara.
- Gráfico adecuado.
- Ejes, unidades, título y fuente.
- Paleta legible y accesible.
- Código reproducible.
- Conclusión prudente.

7. Compruebe su comprensión

1. ¿Qué gráfico usaría para comparar matrículas entre cursos?

- A. Histograma
- B. Barras
- C. Dispersión
- D. KDE

2. ¿Qué gráfico ayuda a ver una tendencia mensual?

- A. Líneas
- B. Pastel
- C. Caja

- D. Treemap

3. ¿Cuál muestra la distribución de las notas?

- A. Barras agrupadas
- B. Histograma
- C. Dona
- D. Líneas

4. En un boxplot, la línea dentro de la caja representa generalmente:

- A. La media
- B. El máximo
- C. La mediana
- D. La moda

5. ¿Qué afirmación es correcta sobre correlación?

- A. Prueba causalidad
- B. Siempre es positiva
- C. Mide asociación, no causalidad
- D. Solo sirve para categorías

6. ¿Cuándo es preferible una barra horizontal?

- A. Etiquetas largas
- B. Fechas diarias
- C. Una distribución
- D. Dos variables continuas

7. ¿Qué riesgo tiene truncar el eje de una barra?

- A. Reduce el archivo
- B. Exagera diferencias
- C. Ordena los datos
- D. Elimina nulos

8. ¿Qué biblioteca ofrece gráficos estadísticos con sintaxis compacta?

- A. sqlite3
- B. pathlib
- C. seaborn
- D. json

9. ¿Qué función abre un CSV con pandas?

- A. pd.read_csv
- B. plt.csv
- C. sns.load
- D. sqlite.open

10. ¿Qué gráfico conviene para progreso frente a nota?

- A. Dispersión
- B. Dona
- C. Barras apiladas
- D. Treemap

11. Una barra 100 % sirve principalmente para comparar:

- A. Totales absolutos

- B. Proporciones
- C. Fechas
- D. Valores atípicos

12. ¿Qué debe acompañar siempre una visualización?

- A. Efecto 3D
- B. Muchos colores
- C. Una interpretación basada en datos
- D. Un logo grande

Uso responsable de IA

Puede solicitar explicaciones o ayuda para depurar, pero debe declarar qué solicitó, verificar el código con los datos, explicar cada gráfico con sus propias palabras y no inventar hallazgos. Copiar una interpretación sin comprobarla no demuestra aprendizaje.